

Введение в BigData

11.02.2025



Содержание

- 1** Немного истории
- 2** Архитектура решений
- 3** Наши дни
- 4** Игроки на РФ рынке
- 5** Немного практики

01

Немного истории



Немного истории

1. 70-ые— Эдгар Кодд появления реляционной модели данных;
2. 80-ые — Пол Мерфи, Барри Девлин “Business DWH”;
3. 90-ые — Появления Oracle, Teradata, IBM D2. Модели Билла Инмона и Ральфа Кимбалла;
4. 00-ые — MPP субд, появление Greenplum, Hadoop; Термин BigData(Клиффорд Линч)
5. 10-ые — Эпоха облаков (Snowflake, G BigQuery, Amazon Redshift)
6. 20-ые — Trino, YugaByte и новые.


02

Архитектура решений



Архитектура решений

Key Layers in Data Stack



Source Layer

1. **Files, SFTP, etc** – файловые ресурсы(Excel, csv, FTP|SFTP);
2. **IOT** – internet of things, устройства умного дома, медицинское оборудование и т.д;
3. **API** – Application programming interface, программный интерфейс для получения данных;
4. **OLTP** – Online Transaction Processing. Системы обработки транзакций в реальном времени.


Data processing

1. **Batch** – ELT, ETL(Extract, Load, Transform и Extract, Transform, Load).
Системы передачи **порционных** данных сырых данных с источника.
2. **Streaming** – обработка данных в реальном времени.

Storage

1. **DWH** – Хранилище данных. Это система для хранения и управления большими объемами структурированных данных, которые объединяются из различных источников с целью получения из них бизнес выгоды (G BigQuerry, Amazon Redshift, Snowflake, Greenplum).
2. **Data Lake** – Озеро данных. Это инструмент хранения необработанных(неструктурированных) данных в различных форматах (Amazon S3, Minio, G Cloud Storage, Yandex S3).
3. **Data Lakehouse** – Объединение концепции DWH и Data Lake. Храним все виды данных и управляем метаданными.


Storage



Science&Experimentation

1. Adhoc — запросы к источнику данных для получения метрик, подтверждения гипотез;
2. Скрипты, аналитика и т.д.
3. ML модели.

BI




03

Наши дни



Наши дни



Наши дни

State of Data and AI Engineering 2025

[Explore the table »](#)

Presented by  lakeFS

INGEST	DATA LAKE	DATA VERSION CONTROL	COMPUTE ENGINES	PIPELINES	PRACTITIONER APPS	GOVERNANCE
Ingest Tech  Google Cloud Pub/Sub  Apache Storm  Amazon Kinesis  StreamNative  Kafka  Beam  Memphis.dev  Nifi  Delta  Flink  Azure Data Factory  Redpanda  Decodable  WarpStream  Informatica  Spark  Pulsar  Airbyte  Confluent  Meltano  Kaskada  Upsolver  Materialize  Striim Ingest SaaS  Portable  Airbyte  Hevo  Polytomic  Fivetran  Twilio Segment  Datadog  Rudderstack  Estuary  Integrate.io  Snowplow  Trocco  Keboola  Rivery  Matillion Reverse ETL  Census  Hightouch  HeadsUp  Polytomic  Seekwell  Grouparoo  Omnato  Rudderstack  Octolis  Trocco	Object Storage  Microsoft Azure Blob Storage  Google Cloud Storage  Amazon S3					
<div> Oracle Cloud</div> <div> IBM Cloud</div> <div> Alibaba Cloud</div> <div> Hadoop</div> <div> Minio</div> <div> Zadara</div> <div> CloudFiles</div> <div> DigitalOcean</div> <div> Cloudflare</div> <div> Storj</div> <div> Wasabi</div> <div> PureStorage</div> <div> StorageGRID</div> <div> Vast</div> <div> Backblaze</div> <div> IDrive</div> <div> Ceph</div> | <div> lakeFS</div> <div> Quilt</div> <div> DVC</div> <div> Oxen.ai</div> <div> Underhive</div> <div> Nessie</div> <div> Git LFS</div> <div> Pachyderm</div> <div>METADATA</div> <div>Metastores</div> <div> Databricks Unity Catalog</div> <div> Azure Purview</div> <div> Tabular</div> <div> Cloud DataProc</div> <div> AWS Glue</div> <div> Cloudera</div> <div> OpenHouse</div> <div> Gravitino</div> <div>Open Table Formats</div> <div> Onehouse</div> <div> Hudi</div> <div> Iceberg</div> <div> Delta Lake</div> <div> ORC</div> | <div>Distributed Compute</div> <div> Databricks</div> <div> Cloudera</div> <div> Cloud Dataproc</div> <div> Spark</div> <div> Ray</div> <div> Hadoop</div> <div> Ascend.io</div> <div> Google DataFlow</div> <div> Dask</div> <div> Azure HDInsight</div> <div> Amazon EMR</div> <div> Trino</div> <div> Akka</div> <div> Bodai</div> <div> Azure Databricks</div> <div> Azure Synapse Analytics</div> <div>Analytics Engines</div> <div> Data Fusion</div>
<div> Google Big Query</div> <div> Amazon Redshift</div> <div> Snowflake</div> <div> Databricks Data Lakehouse</div> <div> Apache Impala</div> <div> StarRocks</div> <div> Firebolt</div> <div> Hazelcast</div> <div> ClickHouse</div> <div> Amazon Athena</div> <div> LakeSoul</div> <div> Dremio</div> <div> SingleStore</div> <div> Materialize</div> <div> QuestDB</div> <div> Redis</div> <div> KX</div> <div> Pinot</div> <div> Polaris</div> <div> Trino</div> <div> DuckDB</div> <div> Rockset</div> <div> Imply</div> <div> Pentaho</div> <div> Star+tree</div> <div> Duke</div> <div> Druid</div> <div> Starburst</div> <div> Yellowbrick</div> <div> dbt</div> <div> Voltron Data</div> <div> Hydra</div> <div> Doris</div> <div> Presto</div> | <div>Orchestration</div> <div> Cloud Workflows</div> <div> Stitch</div> <div> Shipyards</div> <div> AstroJRMER</div> <div> Flyte</div> <div> Union</div> <div> Sequera</div> <div> Dagster</div> <div> Prefect</div> <div> Dagworks</div> <div> Kestra</div> <div> Airflow</div> <div> Sematic</div> <div> Mage</div> <div> MLTWS</div> <div> Metaflow</div> <div> Ugi</div> <div> Kubeflow</div>
<div> Orkes</div> <div> Azkaban</div> <div> Data Quality / Observability</div> <div> Kensu</div> <div> Whylabs</div> <div> Great Expectations</div> <div> Re</div> <div> Metaplane</div> <div> Soda</div> <div> Lightup</div> <div> Datafold</div> <div> Bigeye</div> <div> Acceldata</div> <div> Anomalo</div> <div> HoloClean</div> <div> Union Pandera</div> <div> Monte Carlo</div> <div> Apache Griffin</div> <div> Unravel</div> <div> Databand</div> <div> Elementary</div> <div> AWS Labs/deequ</div> <div> Foundational</div> <div> Timeseer.ai</div> <div> Datorios</div> | <div>MLOps End-to-End</div> <div> ABACUS.AI</div> <div> mlflow</div> <div> Metaflow</div> <div> Baseten</div> <div> AIBLE</div> <div> DataRobot</div> <div> Vertex AI</div> <div> Cnvr.io</div> <div> Hugging Face</div> <div> Seldon</div> <div> Wallaroo.AI</div> <div> Domino</div> <div> Kedro</div> <div> Weights & Biases</div> <div> Graft</div> <div> Kubeflow</div> <div> FEAST</div> <div> CLEAR ML</div> <div> H2O.ai</div> <div> dotData</div> <div> SaturnCloud</div> <div> Neptune.ai</div> <div> Comet</div> <div> ZenML</div> <div> Modular</div> <div> Azure Machine Learning</div> <div> BentoML</div> <div> DagsHub</div> <div> dataiku</div> <div> Qwak</div> <div> Valohai</div> <div>
Databricks Data Intelligence Platform</div> <div> Uber Michelangelo</div> <div> Tacton</div> <div> Hopsworks</div> <div> DVC</div> <div> Amazon SageMaker</div> <div>Data Centric AI/ML</div> <div> Datachain</div> <div> Scale</div> <div> Graviti</div> <div> Snorkel</div> <div> FAL.ai</div> <div> DataLoop</div> <div> Gretel</div> <div> StackAI</div> <div> Pachyderm</div> <div> Voxel51</div> <div> Dstack</div> <div> DVID</div> <div> DataLad</div> <div> ActiveLoop</div> <div> Tasq.ai</div> <div> Hudi</div> <div> Labelbox</div> <div> V7</div> <div> Toloka</div> <div> YData</div> <div>ML/AI Observability & Monitoring</div> <div> Deepchecks</div> <div> Mona</div> <div> Superwise</div> <div> Arthur</div> <div> Fiddler</div> <div> FirstEigen</div> <div> Truera</div> <div> Census</div> <div> Whylabs</div> <div> Evidently AI</div> <div> Galileo</div> <div> HoneyHive</div> <div> AiMon</div> <div> Hydrosphere.io</div> <div> Giskard</div> <div> How/so</div> <div> Aporia</div> <div> NannyML</div> <div> Robust Intelligence</div> <div> LatticeFlow</div> <div> Patronus AI</div> <div> Distributional</div> <div> Braintrust</div> <div> Arize</div> <div>Vector DBs</div> <div> Pinecone</div> <div> MongoDB</div> <div> Milvus</div>
<div> Chroma</div> <div> Marqo</div> <div> DeepLake</div> <div> ActiveLoop</div> <div> FalkorDB</div> <div> Drant</div> <div> Elastic</div> <div> Vespa</div> <div> Google ScaNN</div> <div> Pgvector</div> <div> KX</div> <div> FAISS</div> <div> ClickHouse</div> <div> Vald</div> <div> Weaviate</div> <div> Zilliz</div> <div> Cassandra</div> <div> OpenSearch</div> <div> Tigris</div> <div>Notebooks</div> <div> Jupyter</div> <div> Apache Zeppelin</div> <div> Hex</div> <div> Count</div> <div> Deepnote</div> <div> Cocalc</div> <div> Querybook</div> <div> Databricks Delta Live Tables</div> <div> Kaggle</div> <div> CloudBank</div> <div> Databricks Notebooks</div> <div> Interact</div> <div> Google Colab</div> <div> DL</div> <div>Analytics Workflows</div> <div> Google Cloud Dataform</div> | <div>Data Catalog / Governance</div> <div> Meta Cat</div> <div> Ckan</div> <div> Open Metadata</div> <div> Iguazio</div> <div> Nemo</div> <div> Amundsen</div> <div> DataHub</div> <div> atlan</div> <div> Alation</div> <div> Boomi</div> <div> big.id</div> <div> Magda</div> <div> data.world</div> <div> Collibra</div> <div> Zeenea</div> <div> Satori</div> <div> Platform</div> <div> Raito</div>
<div> Marquez</div> <div> Apache Atlas</div> <div> Google Cloud Dataproc Metastore</div> <div> Databricks Unity Catalog</div> <div> MMUTA</div> <div> IBM Knowledge Catalog</div> <div> Acryl Data</div> <div> Datastrato</div> <div> SELECT STAR</div> |

04


Игроки на рынке



Tbank(~2018)




Сберздоровье(~2022)




Okko(~2023)

Архитектура



5




LemanaPro(~2022)




Whoosh(~2023)




BestDoctor(~2022)




Xbox Microsoft(~2022)



Amazon Retail(~2022)




Skyeng(~2025)



Y.Market(~2025)

как устроено потребление данных в Маркете



Ostrovok(~2025)


платформа dota v.2: текущее состояние



O!


Передовые решения (~2025)

Аналитическая инфраструктура 2.0.



05

Немного практики



Настройка

1. <https://www.docker.com/products/docker-desktop/>
2. <https://github.com/zezOtik/bmstu--iu8-big-data-tools>
3. <https://dbeaver.io/>